26-如何提高JSON解析的性能?

你好,我是戴铭。

在iOS 开发中,我们都会碰到这样的问题:不同团队开发的库需要进行数据通信,而通信数据规范通常很难确定。今天,我们就来聊聊如何高效地解决这个问题吧。

同一个编程语言之间的数据通信非常简单,因为数据的规范都是相同的,所以输入和输出不需要做任何转换。但是,在不同编程语言之间进行数据通信,就会比较麻烦了。比如,一种语言按照自身的标准规范输出了一份数据,另一门语言接收到时需要依据自身编程语言标准进行数据对齐。

对齐一门语言的数据或许你还能够接受,但是如果对接的语言多了,你就需要写很多份能够与之对应的数据 对齐转换代码。编写和维护的成本可想而知,那么目前有没有一种通用,而且各个编程语言都能支持的数据 格式呢?

答案是有的。这个数据格式,就是我今天要跟你聊的JSON。

接下来,在今天这篇文章中,我会先和你聊聊什么是 JSON;然后,再和你说说 JSON 的使用场景,以及 iOS 里是如何解析 JSON 的;最后,再和你分析如何提高 JSON 的解析性能。

什么是 JSON?

JSON ,是JavaScript Object Notation的缩写。其实,JSON最初是被设计为 JavaScript 语言的一个子集,但最终因为和编程语言无关,所以成为了一种开放标准的常见数据格式。

虽然JSON源于 JavaScript,但到目前很多编程语言都有了 JSON 解析的库,包括 C、C++、Java、Perl、Python 等等。除此之外,还有很多编程语言内置了 JSON 生成和解析的方法,比如 PHP 在5.2版本开始内置了 json_encode() 方法,可以将 PHP 里的 Array 直接转化成 JSON。转换代码如下:

```
$arr = array(array(7,11,21));
echo json_encode($arr)."<br/>
$dic = array('name1' => 'val1', 'name2' => 'val2');
echo json_encode($dic)
```

输出结果如下:

```
[[7,11,21]]
{"name1":"val1","name2":"val2"}
```

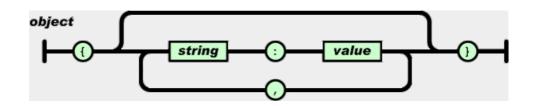
如上所示,生成了两个 JSON 对象,第一个解析完后就是一个二维数组,第二个解析完后就是一个字典。有 了编程语言内置方法解析和生成 JSON 的支持,JSON 成为了理想的数据交换格式。

通过上面生成的 JSON 可以看出,JSON 这种文本数据交换格式易读,且结构简单。

JSON基于两种结构:

- 名字/值对集合:这种结构在其他编程语言里被实现为对象、字典、Hash 表、结构体或者关联数组。
- 有序值列表: 这种结构在其他编程语言里被实现为数组、向量、列表或序列。

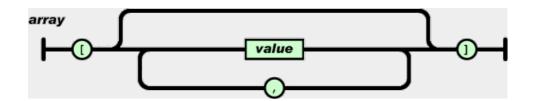
各种编程语言都以某种形式支持着这两种结构。比如,PHP的 Array 既支持名字/值对集合又支持有序值列表;在 Swift 里键值集合就是字典,有序值列表就是数组。**名字/值对集合**在 JSON 和 JavaScript 里都被称为对象。JSON语法图以及说明,你可以在 JSON 官网查看。在这里,我只列出了几个用的比较多的语法图。



如上面语法图所示,对象是以左大括号开头和右大括号结尾,名字后面跟冒号,名字/值对用逗号分隔。比如:

```
{"name1":"val1","name2":"val2"}
```

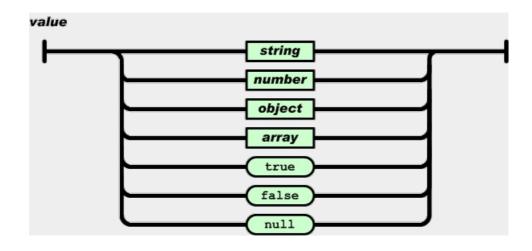
有序值列表在 JSON 和 JavaScript 里都叫数组,其语法图如下:



可以看出数组是以左中括号开头,以右中括号结尾,值以逗号分隔。数组代码如下所示:

```
[[7,11,21]]
```

语法图中值的语法图如下:



可以看出,值可以是字符串、数字、对象、数组、布尔值ture、布尔值false、空值。根据这个语法,JSON 可以通过实现对象和数组的嵌套来描述更为复杂的数据结构。

JSON 是没有注释的,水平制表符、换行符、回车符都会被当做空格。字符串由双引号括起来,里面可以使 零到多个 Unicode 字符序列,使用反斜杠来进行转义。

JSON的使用场景

JSON 的数据结构和任何一门编程语言的语法结构比起来都要简单得多,但它能干的事情却一点儿也不少, 甚至可以完整地描述出一门编程语言的代码逻辑。比如,下面的这段 JavaScript 代码:

```
if (hour < 18) {
 greeting = "Good day";
}
```

这段 JavaScript 代码的逻辑是,当 hour 变量小于18时,greeting 设置为 Good day 字符串,根据 JavaScript 的语法规则,完整逻辑的语法树结构可以通过 JSON 描述出来。对应的JSON,如下:

```
{
 "type": "Program",
 "body": [
   {
     "type": "IfStatement",
     "test": {
       "type": "BinaryExpression",
       "left": {
         "type": "Identifier",
         "name": "hour"
       },
        "operator": "<",
        "right": {
         "type": "Literal",
         "value": 18,
         "raw": "18"
       }
     },
      "consequent": {
        "type": "BlockStatement",
        "body": [
            "type": "ExpressionStatement",
            "expression": {
              "type": "AssignmentExpression",
              "operator": "=",
              "left": {
               "type": "Identifier",
               "name": "greeting"
              },
              "right": {
                "type": "Literal",
                "value": "Good day",
                "raw": "\"Good day\""
```

```
}
}

l

l

l

l

land

"alternate": null

}

l,

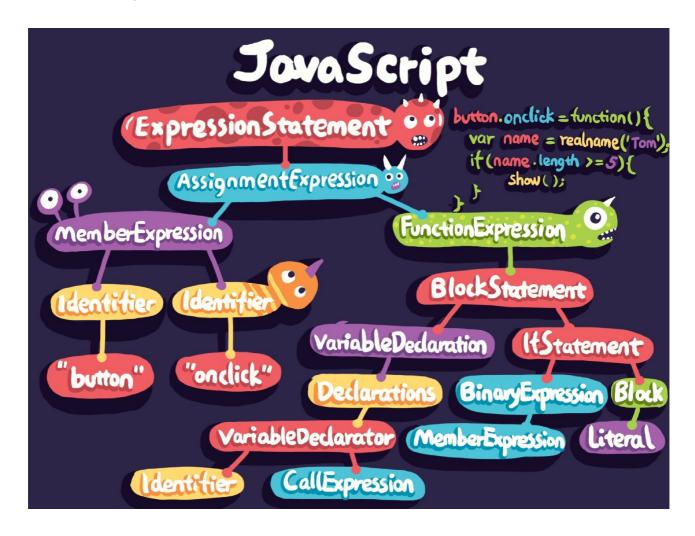
"sourceType": "module"
}
```

从上面的 JSON 代码可以看出,每个语法树节点都是一个 JSON 对象,同级节点使用的是 JSON 数组。 JavaScript 语法规则标准可以在Ecma 网站上找到。

比如下面这段 JavaScript 代码:

```
button.onclick = function() {
   var name = realname('Tom');
   if(name.length >= 5) {
      show();
   }
}
```

上面这段 JavaScript 代码对应的语法树如下图所示:



Swift,都能够生成自己的语法树结构,转成 JSON 后能够在运行期被动态地识别。因此,**App 的业务逻辑动态化就不仅限于使用 JavaScript 这一门语言来编写,而是可以选择使用其他你熟悉的语言。**

JSON 不仅可以描述业务数据使得业务数据能够动态更新,还可以用来描述业务逻辑,以实现业务逻辑的动态化,除此之外还可以用来描述页面布局。比如,我以前就做过这么一件事儿:解析一个H5页面编辑器生成的 JSON,将 JSON 对应生成 iOS 原生界面布局代码。我当时是用 Swift 语言来编写这个项目的,完整代码在这里。

在这个项目中,对JSON 的解析使用的是系统自带的 JSONDecoder 的 decode 方法,具体代码如下:

```
let jsonData = jsonString.data(using: .utf8)!
let decoder = JSONDecoder()
let jsonModel = try! decoder.decode(H5Editor.self, from: jsonData)
```

上面代码中的,H5Editor 是一个结构体,能够记录 JSON 解析后的字典和数组。H5Editor 结构体完整定义,请点击<mark>这里的链接</mark>。

那么, JSONDecoder 的 decode 方法到底是怎么解析 JSON 的呢?在我看来,了解这一过程的最好方式,就是直接看看它在Swift 源码里是怎么实现的。

JSONDecoder 如何解析 JSON?

JSONDecoder 的代码,你可以在 Swift 的官方 GitHub 上查看。

接下来,我先跟你说下解析 JSON 的入口, JSONDecoder 的 decode 方法。下面是 decode 方法的定义代码:

```
open func decode<T : Decodable>(_ type: T.Type, from data: Data) throws -> T {
    let topLevel: Any
    do {
        topLevel = try JSONSerialization.jsonObject(with: data)
    } catch {
        throw DecodingError.dataCorrupted(DecodingError.Context(codingPath: [], debugDescription: "The give
    }
    // JSONDecoder 的初始化
    let decoder = __JSONDecoder(referencing: topLevel, options: self.options)
    // 从顶层开始解析 JSON
    guard let value = try decoder.unbox(topLevel, as: type) else {
        throw DecodingError.valueNotFound(type, DecodingError.Context(codingPath: [], debugDescription: "Th
    }
    return value
}
```

接下来,我们通过上面的代码一起来看看 decode 方法是如何解析 JSON 的。

上面 decode 方法入参 T.type 的 T 是一个泛型,具体到解析H5页面编辑器生成的 JSON 的例子,就是

H5Editor 结构体;入参 data 就是 JSON 字符串转成的 Data 数据。

decode 方法在解析完后会将解析到的数据保存到传入的结构体中,然后返回。在 decode 方法里可以看到,对于传入的 Data 数据会首先通过 JSONSerialization 方法转化成 topLevel 原生对象,然后topLevel 原生对象通过 JSONDecoder 初始化成一个 JSONDecoder 对象,最后使用 JSONDecoder 的 unbox 方法将数据和传入的结构体对应上,并保存在结构体里进行返回。

可以看出,目前 JSONSerialization 已经能够很好地解析 JSON,JSONDecoder将其包装以后,通过 unbox 方法使得 JSON 解析后能很方便地匹配 JSON 数据结构和 Swift 原生结构体。

试想一下,如果要将 JSON 应用到更大的场景时,比如对编程语言的描述或者界面布局的描述,其生成的 JSON 文件可能会很大,并且对这种大 JSON 文件解析性能的要求也会更高。那么,有比JSONSerialization性 能更好的解析JSON的方法吗?

提高 JSON 解析性能

2019年2月,Geoff Langdale 和 Daniel Lemire发布了 <u>simdjson</u>。 simdjson是一款他们研究了很久的快速 JSON 解析器, 号称每秒可解析千兆字节 JSON 文件。simdjson 和其他 JSON 解析器对比如下图所示:

parser	GB/s
simdjson	2.2
RapidJSON encoding-validation	0.51
RapidJSON encoding-validation, insitu	0.71
sajson (insitu, dynamic)	0.70
sajson (insitu, static)	0.97
dropbox	0.14
fastjson	0.26
gason	0.85
ultrajson	0.42
jsmn	0.28
cJSON	0.34

可以看出,只有 simdjson 能够达到每秒千兆字节级别,并且远远高于其他 JSON 解析器。那么 ,simdjson 是怎么做到的呢?接下来,我通过 simdjson 解析 JSON 的两个阶段来跟你说明下这个问题。

第一个阶段,使用 simdjson 去发现需要 JSON 里重要的字符集,比如大括号、中括号、逗号、冒号等,还有类似 true、false、null、数字这样的原子字符集。第一个阶段是没有分支处理的,这个阶段与词法分析非常类似。

第二个阶段,simdjson 也没有做分支处理,而是采用的堆栈结构,嵌套关系使用 goto 的方式进行导航。 simdjson 通过索引可以处理所有输入的 JSON 内容而无需使用分支,这都归功于聪明的条件移动操作,使得遍历过程变得高效了很多。

通过 simdjson 解析 JSON 的两个阶段可以看出,simdjson的主要思路是尽可能地以最高效的方式将 JSON 这种可读性高的数据格式转换为计算机能更快理解的数据格式。

为了达到快速解析的目的, simdjson在第一个阶段一次性使用了 64字节输入进行大规模的数据操作,检查字符和字符类时以及当获得掩码应用变换时以64位进行位操作。这种方式,对于大的 JSON 数据解析性能提升是非常明显的。

如果你想更详细地了解这两个阶段的解析思路,可以查看这篇论文"<u>Parsing Gigabytes of JSON per</u> <u>Second</u>"。其实,simdjson 就是对这篇论文的实现,你可以在<u>GitHub</u>上查看具体的实现代码。在我看来,一边看论文,一边看对应的代码实现,不失为一种高效的学习方式。

而如果你想要在工程中使用 simdjson的话,直接使用它提供的一个简单接口即可。具体的使用代码如下:

```
#include "simdjson/jsonparser.h"

/...

const char * filename = ... // JSON 文件
std::string_view p = get_corpus(filename);
ParsedJson pj = build_parsed_json(p); // 解析方法
// you no longer need p at this point, can do aligned_free((void*)p.data())
if( ! pj.isValid() ) {
    // 出错处理
}
aligned_free((void*)p.data());
```

小结

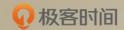
在今天这篇文章中,我和你分享了什么是 JSON,JSON 的使用场景,以及simdjson 这个开源 JSON 解析库。simdjson 能够极大地提高 JSON 解析性能,你也可以非常方便地把它用到自己的工程中。

当需要对现有方案进行优化时,有的人会利用自己扎实的计算机基础知识找出更优秀的解决方案,而有的人只能等待更优秀的解决方案的出现。simdjson的作者明显就属于前者,而我们也要不断充实自己的基础知识,努力成为这其中的一员。

课后小作业

对于 JSON 的解析库,我今天只和你分析了系统自带的 JSONSerialization 和 simdjson。那么,我想请你说说你目前使用的 JSON 解析库是什么,以及它是如何解析 JSON 的,性能又如何呢?

感谢你的收听,欢迎你在评论区给我留言分享你的观点,也欢迎把它分享给更多的朋友一起阅读。



iOS 开发高手课

从原理到实战,带你解决80%的开发难题

戴铭

前滴滴出行技术专家



新版升级:点击「探请朋友读」,20位好友免费读,邀请订阅更有现金奖励。

精选留言:

● 张蒙 2019-05-09 06:17:57 戴老师给我传达的思维方式。阶段一,能用就好。阶段二,能不能更好。显然,第二种更有利于自己的进 步。 [5赞]

• bo 2019-05-09 10:00:52

NSJSONSerialization 在解析值是 null 的时候。并不会百分之百返回 NSNull,结果是随机的。有空数组,NSNull,还有值是 0 的 NSNumber。由于业务没有过滤 NSNumber 导致把它当作 NSDictionary 来处理出现了消息不响应的 crash。对于这类问题,老师是否有好的解决办法? [1赞]

• Jeffrey 2019-05-09 06:41:07

我用的是Objective-C Foundation中自带的方法 NSJSONSerialization来解析json 本文中提到的simdjson 比iOS系统自带的json解析效率高吗?是不是以后可以用simdjson来替代 NSJsonSerialization [1赞]

- 谭鹏 2019-05-10 09:01:04 JSONKit 效率很好
- 这个shaonian不太冷、2019-05-10 01:32:23Simdjson如何在iOS中使用呢
- 连腾锋 2019-05-09 10:52:13YYmodel 方便,效率还好
- 梅长苏 2019-05-09 09:28:01那mjextention解析效率如何?